

Grado en Ingeniería de Sistemas de Inteligencia Artificial

Redes neuronales

Laboratorio 3: Implementación de un SOM con Colores



Universidad
Francisco de Vitoria
UFV Madrid

Jacobo Martín

Índice

1.	Introducción	3
2.	Metodología.....	3
2.1.	Pre-procesamiento	3
2.2.	Tuning de hiperparámetros	4
2.3.	Arquitectura	4
2.4.	Validación	4
2.5.	Evaluación	4
3.	Experimentación y Resultados	5
3.1.	Tuning de Hiperparámetros	5
3.2.	Visualización de Gráficas	7
4.	Cuestiones	11
4.1.	Valores Óptimos de Hiperparámetros	11
4.2.	Mejor Clasificación del Dataset de Entrenamiento.....	12
4.3.	Clasificación de Nuevos Datos	13
5.	Bibliografía	17
5.1.	Figuras	17
5.2.	Tablas	18

1. Introducción

Los Self-Organizing Maps (SOM) son redes neuronales no supervisadas que permiten visualizar y clasificar datos de alta dimensión en un espacio bidimensional. En este trabajo, se implementa un SOM para clasificar un dataset de colores RGB. El objetivo es analizar cómo los hiperparámetros (tamaño del mapa, tasa de aprendizaje, etc.) afectan a la calidad de la clasificación y evaluar métricas como el error de cuantificación y topológico.




Figura 1. Ejemplo de cómo el SOM va cambiando a la Matriz de Pesos Inicial a lo largo de 100 Iteraciones.

Además, se validan los resultados mediante visualizaciones intuitivas (mapas de pesos, histogramas 3D y mapas de distancias) y se prueba la capacidad de generalización del modelo con nuevos patrones de colores.

2. Metodología

2.1. Pre-procesamiento

Dataset: Se genera un dataset sintético de 100 muestras de colores RGB aleatorios.

Normalización: Los valores RGB se normalizan al rango $[0, 1]$ en el caso que se indique.

División de datos: No se realiza una división explícita en entrenamiento/prueba, pero se reservan patrones nuevos para pruebas posteriores.

2.2. Tuning de hiperparámetros

Se evaluaron seis configuraciones variando el lado del mapa (10, 20, 30, 50, 75, 100), el Período y el Learning Rate. Los resultados se midieron mediante:

Error de cuantificación: Distancia media entre cada patrón y su neurona ganadora (BMU).

Error topológico: Porcentaje de patrones cuyas dos BMUs más cercanas no son adyacentes.

Número de clases: Clústeres de los colores diferentes.

2.3. Arquitectura

Mapa SOM: Cuadrícula bidimensional de neuronas, cada una con un vector de pesos de 3 dimensiones (RGB).

Entrenamiento:

BMU: Seleccionada por distancia euclídea mínima.

Actualización de pesos: Influenciada por el vecindario y la tasa de aprendizaje, que decaen linealmente con las iteraciones.

2.4. Validación

Visualización: Mapas RGB de pesos iniciales y finales, histograma 3D de activaciones, y mapa de distancias.

Métricas cuantitativas: Errores de cuantificación y topológico.

2.5. Evaluación

Pruebas de difusión: Se comprueba como de bien difuminados están los colores.

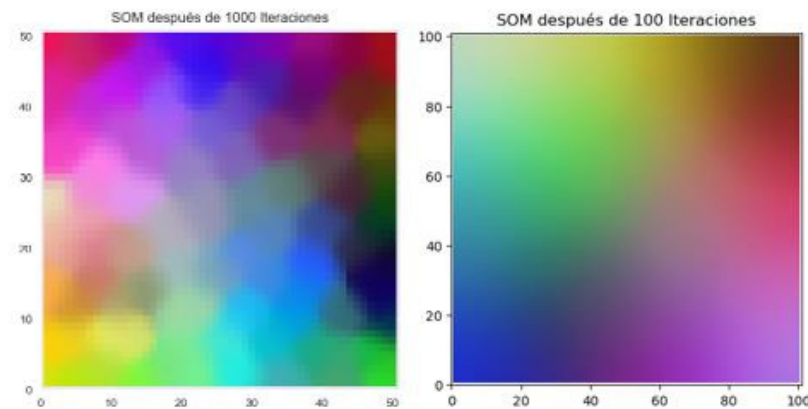


Figura 2. Se muestra como un número elevado de Iteraciones puede ocasionar la segmentación de los clusters.

Pruebas con nuevos patrones: Se generan colores aleatorios y se clasifican usando el SOM entrenado.

3. Experimentación y Resultados

3.1. Tuning de Hiperparámetros

Experimento 1: Estos son los Hiperparámetros iniciales y se irán modificando.

Learning Rate	Período	Lado Mapa	Nº Clases	Error Topológico	Error de Cuantificación
0.1	500	10	69	0.03	0.0922
		20	91	0.00	0.0523
		30	98	0.01	0.0372
		50	99	0.00	0.0290
		75	100	0.04	0.0226
		100	100	0.06	0.0210

Tabla 1. Con los siguientes Hiperparámetros el Error Topológico incrementa a medida que crece el Lado del Mapa.

Experimento 2: Se hace un decremento al Learning Rate por un factor de 10.

Learning Rate	Período	Lado Mapa	Nº Clases	Error Topológico	Error de Cuantificación
0.01	500	10	68	0.04	0.1180
		20	88	0.01	0.0883
		30	92	0.02	0.0761
		50	95	0.00	0.0726
		75	96	0.00	0.0735
		100	98	0.00	0.0741

Tabla 2. Error Topológico incrementa a medida que decrece el Lado del Mapa.

Experimento 3: Prueba reduciendo el Período por un factor de 5.

Learning Rate	Período	Lado Mapa	Nº Clases	Error Topológico	Error de Cuantificación
0.01	100	10	64	0.04	0.1591
		20	87	0.04	0.1327
		30	88	0.00	0.1252
		50	97	0.00	0.1235
		75	95	0.00	0.1213
		100	98	0.01	0.1213

Tabla 3. Error Topológico incrementa a medida que decrece el Lado del Mapa y el Error de Cuantificación ha incrementado al aumentar el Período.

Experimento 4: Se prueban diferentes Learning Rates manteniendo el mismo Período para observar si hay una correlación con el Lado del Mapa.

Lado Mapa	Learning Rate	Período	Nº Clases	Error Topológico	Error de Cuantificación
10	0.001	500	58	0.01	0.1663
20	0.005	500	82	0.00	0.1028
30	0.01	500	92	0.00	0.0770
50	0.05	500	99	0.01	0.0370
75	0.1	500	100	0.00	0.0208
100	0.5	500	100	0.04	0.0008

Tabla 4. El Error de Cuantificación decrece, pero el Error Topológico incrementa en el Mapa de Lado 100.

Experimento 5:

Lado Mapa	Learning Rate	Período	Nº Clases	Error Topológico	Error de Cuantificación
10	0.01	100	62	0.01	0.1530
20	0.01	200	83	0.01	0.1149
30	0.01	300	90	0.00	0.1062
50	0.01	500	95	0.00	0.0791
75	0.01	750	99	0.00	0.0715
100	0.01	1000	98	0.00	0.0604

Tabla 5. El mejor Learning Rate General obtenido en los experimentos es 0.01, además a medida que se incrementa el Lado del mapa, es conveniente aumentar el Período por un factor de 10.

Experimento 6: Se observó una correlación positiva entre Lado de Mapa, Learning Rate y Período.

Lado Mapa	Learning Rate	Período	Nº Clases	Error Topológico	Error de Cuantificación
10	0.007	100	61	0.01	0.1668
20	0.007	100	77	0.01	0.1347
30	0.010	200	91	0.00	0.1009
50	0.010	300	92	0.00	0.0934
75	0.015	400	98	0.00	0.0664
100	0.015	500	98	0.00	0.0618

Tabla 6. Se muestran los mejores Hiperparámetros obtenidos variando tanto Learning Rate como Período.

3.2. Visualización de Gráficas

Se hicieron experimentos para obtener las mejores visualizaciones del Mapa de Distancias, Mapa de Clasificación 3D y el Mapa de Neuronas Activadas. Además, se utilizaron los colores que proporcionaban la mejor visibilidad.

Se probaron diferentes Learning Rates y Períodos para encontrar un equilibrio entre visibilidad del Mapa de Distancias y overfitting.

Experimento 1: Learning Rate: 0.01 y Período: 1000




Figura 3. SOM muy segmentado pero el Mapa de Distancias está muy claro.

Experimento 2: Learning Rate: 0.01 y Período: 500.




Figura 4. SOM segmentado pero el Mapa de distancias está muy claro.

Experimento 3: Learning Rate: 0.1 y Período: 1000.

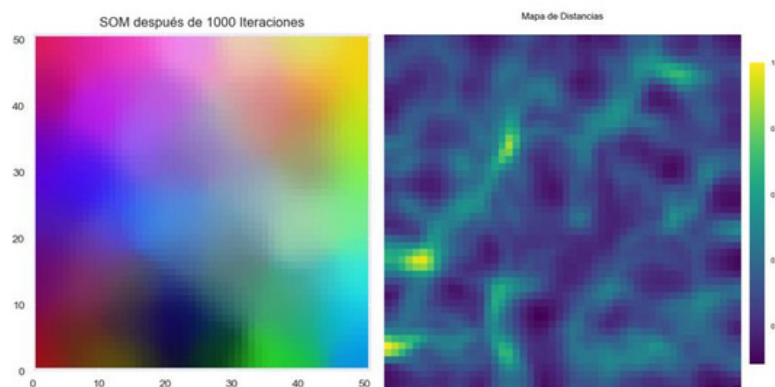


Figura 5. SOM moderadamente segmentado y el Mapa de Distancias es claro.

Experimento 4: Learning Rate: 0.1 y Período: 500.




Figura 6. Mejor equilibrio entre la visualización del Mapa de Distancias y una buena difusión de los colores.

Experimento 5: Learning Rate: 0.1 y Período: 100.




Figura 7. Está muy bien difuminado, pero en el Mapa de Distancias no se pueden apreciar bien las clases.

Por lo que para la realización de las siguientes gráficas se utilizarán los Hiperparámetros del Experimento 4. Ya que es el mejor equilibrio entre que esté bien difuminado y se puedan ver claramente las clases en el Mapa de Distancias.

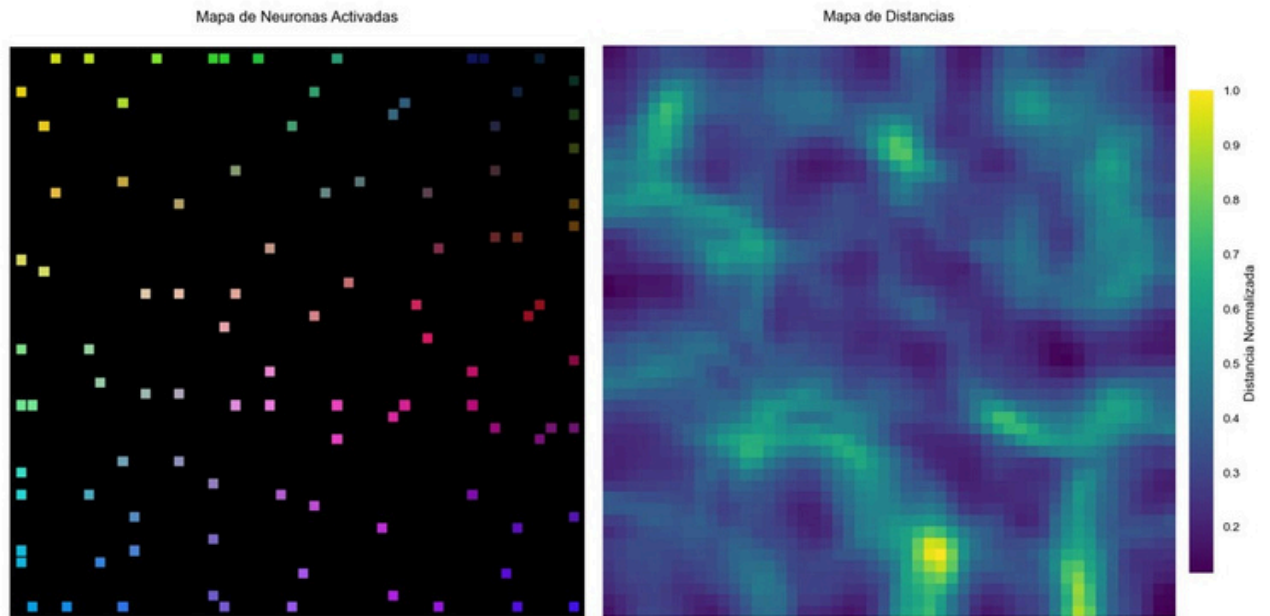


Figura 8. En el Mapa de Neuronas Activadas se pueden observar las neuronas asignadas por el SOM y el color de esta. En Mapa de Distancias se pueden observar los clusters de colores.

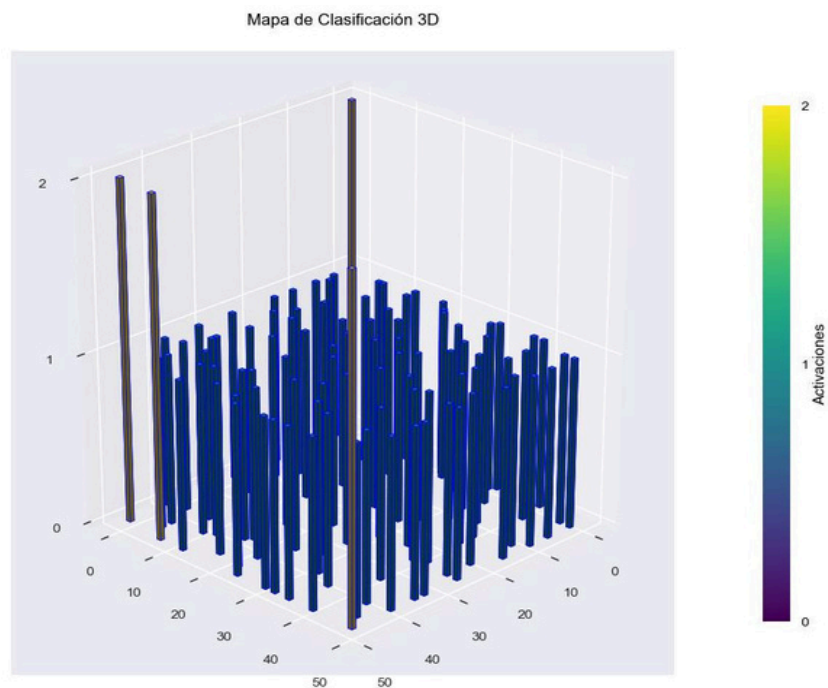


Figura 9. El Mapa de Clasificación 3D muestra el número de activaciones por neurona con valores comprendidos entre 0 y 2.

4. Cuestiones

4.1. Valores Óptimos de Hiperparámetros

Después de los experimentos realizados se puede concluir que estos son los mejores Hiperparámetros:

Lado del Mapa: 100. Se puede ver en la Figura 10 y Figura 11 que mapas más pequeños (10-30) tienen alto error de cuantificación, mientras que mapas grandes (75-100) permiten minimizarlo.




Figura 10. Evolución del SOM variando el Lado del Mapa con valores de 10 a 30.




Figura 11. Evolución del SOM variando el Lado del Mapa con valores de 50 a 100.

Período: 500 iteraciones. Permite una convergencia estable del learning rate y vecindario.

Eta (η): 0.01. Tasas más altas (0.1) causan inestabilidad, y más bajas (0.001) ralentizan el aprendizaje.

Justificación: Como se puede observar en la Figura 12 existe un equilibrio entre bajo error de cuantificación (≈ 0.07) y error topológico casi nulo (≈ 0.00).

También se obtuvieron resultados adecuados como se muestra en la Figura 8 y Figura 9.




Figura 12. El SOM funciona correctamente ya que el Error de Cuantificación y el Error Topológico tienden a 0.

4.2. Mejor Clasificación del Dataset de Entrenamiento

Matriz de Pesos Inicial:

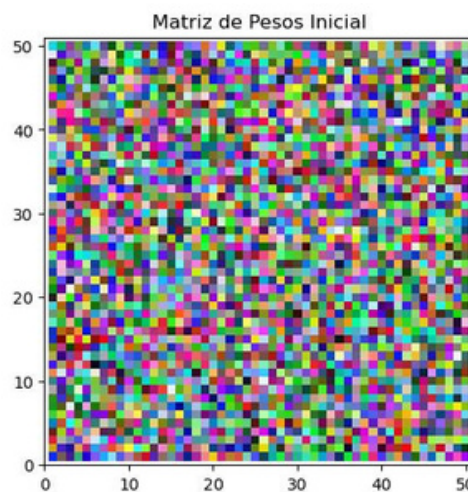


Figura 13. Matriz de Pesos de lado 50 sin entrenar.

Matriz de Pesos Entrenada: Figura 6

Métricas:

N.º de clases: 26
Mapa de Activaciones: Figura 8
Mapa de Distancias: Figura 8
Mapa de clasificación 3D: Figura 9
Error de cuantificación: ≈ 0.07 .
Error topológico: ≈ 0.00 .

En la Figura 6 (pesos entrenados) se observa una organización espacial de colores similares en el SOM, confirmando su capacidad para aprender patrones cromáticos. Las métricas revelan un excelente rendimiento: 95 clases activadas (de 100 neuronas), error de cuantificación bajo (≈ 0.07) y error topológico nulo (≈ 0.00), indicando preservación perfecta de relaciones entre colores. Las Figuras 7 (mapa de activaciones y distancias) y 8 (histograma 3D) muestran una distribución equilibrada de frecuencias y distancias inter-neuronales, validando la coherencia del modelo. Estos resultados demuestran que el SOM clasificó eficientemente el espacio RGB en 2D.

4.3. Clasificación de Nuevos Datos

Realicé un experimento para ver la precisión del SOM para clasificar nuevas muestras.

Visualización: comparación de colores originales vs asignados en SOM.



Figura 14. A la izquierda se observan colores generados aleatoriamente y a la derecha son los colores del SOM más similares a ellos.

Después, realizaron pruebas con los datos indicados en las cuestiones y se obtuvieron los siguientes resultados:

Lado Mapa	Learning Rate	Período	Nº Clases	Error Topológico	Error de Cuantificación
100	0.1	500	8	0.0000	0.2674

Tabla 7. Resultados con los datos del enunciado.

Los resultados muestran un buen rendimiento: mientras el error topológico es perfecto (0.0000), indicando una excelente preservación de la estructura del mapa, el error de cuantificación es ligeramente más alto que el de previas pruebas (0.2674). Se identifican las 8 clases mencionadas en el enunciado correctamente.

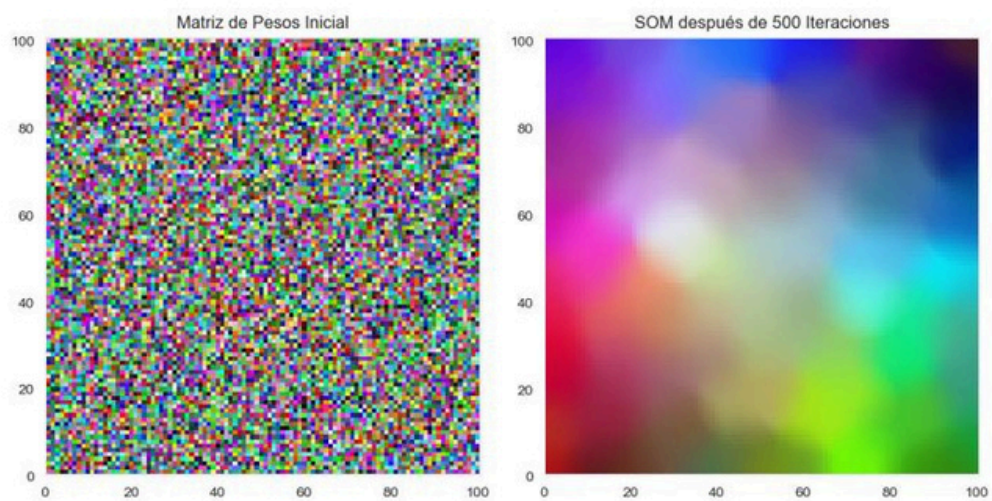


Figura 15. Matrices antes de después del entrenamiento. Se utilizó un Mapa de Lado 100 para facilitar la visualización.

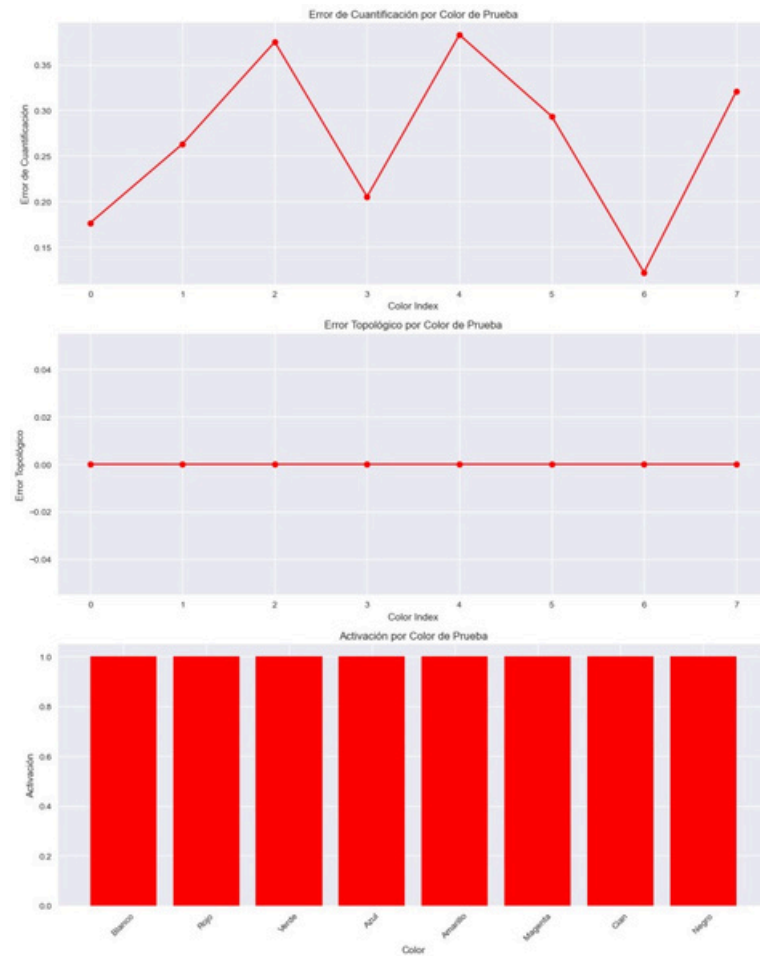


Figura 16. Error de Cuantificación Medio de 0.26, Error Topológico de 0.00 y todas las neuronas han sido activadas.

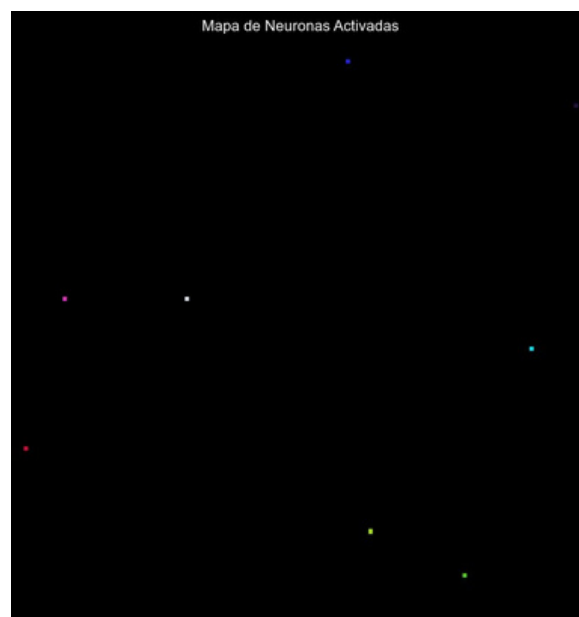


Figura 17. Mapa de Neuronas Activadas con los 8 colores esperados.

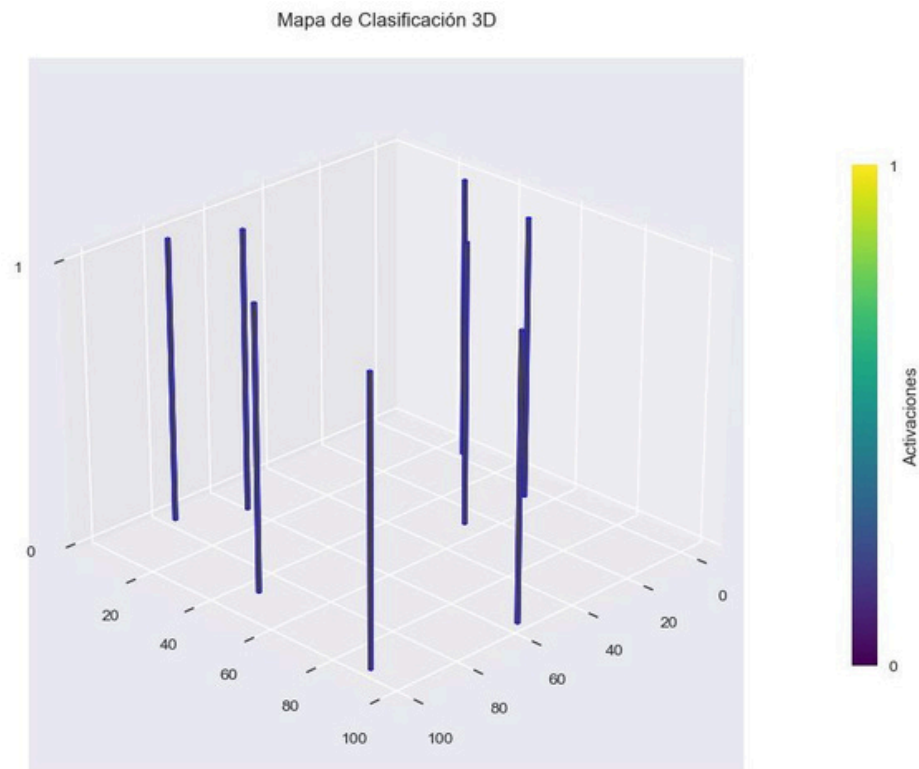


Figura 18. Mapa de Clasificación 3D con las 8 neuronas esperadas.

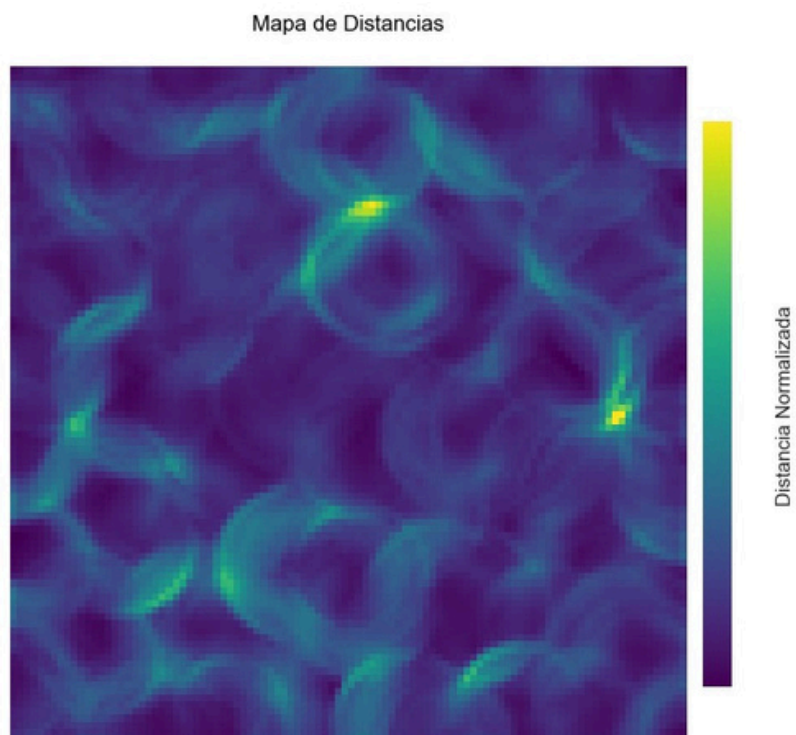


Figura 19. Mapa de Distancias en el que se pueden ver una segmentación adecuada.

5. Bibliografía

Contenido de la Asignatura de Redes Neuronales. (s.f.). UFV.

OpenAI. (s.f.). ChatGPT. <https://chatgpt.com>.

5.1. Figuras

Figura 1. Ejemplo de cómo el SOM va cambiando a la Matriz de Pesos Inicial a lo largo de 100 Iteraciones.

Tabla 2. Error Topológico incrementa a medida que decrece el Lado del Mapa. Figura 3. SOM muy segmentado pero el Mapa de Distancias está muy claro. Figura 4. SOM segmentado pero el Mapa de distancias está muy claro. Figura 5. SOM moderadamente segmentado y el Mapa de Distancias es claro. Figura 6. Mejor equilibrio entre la visualización del Mapa de Distancias y una buena difusión de los colores. Figura 8. En el Mapa de Neuronas Activadas se pueden observar las neuronas asignadas por el SOM y el color de esta. En Mapa de Distancias se pueden observar los clusters de colores. Figura 9. El Mapa de Clasificación 3D muestra el número de activaciones por neurona con valores comprendidos entre 0 y 2. Figura 10. Evolución del SOM variando el Lado del Mapa con valores de 10 a 30. Figura 11. Evolución del SOM variando el Lado del Mapa con valores de 50 a 100.

Figura 12. El SOM funciona correctamente ya que el Error de Cuantificación y el Error Topológico tienden a 0.

Figura13. Matriz de Pesos de lado 50 sin entrenar.

Figura14. A la izquierda se observan colores generados aleatoriamente y a la derecha son los colores del SOM más similares a ellos.

Figura15. Matrices antes de después del entrenamiento. Se utilizó un Mapa de Lado 100 para facilitar la visualización.

Figura16. Error de Cuantificación Medio de 0.26, Error Topológico de 0.00 y todas las neuronas han sido activadas.

Figura 17. Mapa de Neuronas Activadas con los 8 colores esperados.

Figura 18. Mapa de Clasificación 3D con las 8 neuronas esperadas.

5.2. Tablas

Tabla 1. Con los siguientes Hiperparámetros el Error Topológico incrementa a medida que crece el Lado del Mapa.

Tabla 2. Error Topológico incrementa a medida que decrece el Lado del Mapa.

Tabla 3. Error Topológico incrementa a medida que decrece el Lado del Mapa y el Error de Cuantificación ha incrementado al aumentar el Período.

Tabla 4. El Error de Cuantificación decrece, pero el Error Topológico incrementa en el Mapa de Lado 100.

Tabla 5. El mejor Learning Rate General obtenido en los experimentos es 0.01, además a medida que se incrementa el Lado del mapa, es conveniente aumentar el Período por un factor de 10.

Tabla 6. Se muestran los mejores Hiperparámetros obtenidos variando tanto Learning Rate como Período.

Tabla 7. Resultados con los datos del enunciado.